

Proyecto de aula de Álgebra lineal

Primera entrega

Responsables

Andrés Felipe Arteaga G.

Víctor Manuel Monsalve A.

Anderson Monsalve M.

David Santiago Rodríguez R.

Introducción.

El rendimiento académico de los estudiantes está influenciado por diversos factores, tales como sus calificaciones, nivel de asistencia, hábitos de estudio, entorno familiar y motivación personal. Comprender cómo interactúan estos elementos puede permitir a las instituciones educativas implementar estrategias más efectivas para apoyar a sus estudiantes. Sin embargo, a menudo esta información no se utiliza de manera integral para prevenir dificultades o potenciar el aprendizaje.

Este proyecto tiene como propósito aprovechar técnicas de Análisis de Componentes Principales (PCA) y algoritmos de Machine Learning para procesar y analizar datos académicos, con el fin de generar recomendaciones personalizadas para los estudiantes. A través de esta metodología, se podrán identificar patrones de rendimiento, predecir posibles riesgos académicos y sugerir materias o estrategias de estudio adaptadas a las necesidades individuales de cada estudiante.

Como punto de partida, se puede solicitar la generación de una introducción más amplia mediante un modelo de lenguaje (LLM) con un prompt como:

"Hola, actúa como un experto en educación. Realiza una introducción sobre los factores que inciden en el rendimiento académico con enlaces válidos para validar la información."

Una vez obtenida la respuesta del modelo, será necesario contrastar sus afirmaciones con fuentes confiables para evitar posibles alucinaciones o errores conceptuales.

Es importante definir desde el inicio si el proyecto se centrará en un sistema de clasificación de rendimiento académico o en un sistema de recomendaciones personalizadas, para garantizar un enfoque claro y consistente en el desarrollo. En este caso, se propone centrarse exclusivamente en la clasificación, para delimitar el alcance y facilitar la implementación y validación de los modelos.

.

Propósito U objetivos.

Objetivo General

- Desarrollar un sistema de análisis académico basado en PCA y Machine Learning para identificar patrones en el rendimiento estudiantil y clasificar a los estudiantes según su desempeño.

Objetivos Específicos

- Aplicar el Análisis de Componentes Principales (PCA) para identificar los factores clave que influyen en el rendimiento académico.
- Implementar algoritmos de Machine Learning para clasificar a los estudiantes de acuerdo con su perfil de rendimiento.
- Evaluar la efectividad del sistema de clasificación utilizando métricas adecuadas (precisión, recall, F1-score, entre otras).
- Visualizar los resultados a través de un dashboard interactivo que facilite la toma de decisiones pedagógicas.

Idea del proyecto

El proyecto consiste en utilizar técnicas de PCA y algoritmos de Machine Learning para analizar datos académicos de los estudiantes, tales como calificaciones, asistencia y hábitos de estudio. El objetivo es procesar esta información para identificar los factores más relevantes que inciden en el rendimiento académico y, con base en ellos, clasificar a los estudiantes en diferentes categorías de desempeño.

Esta clasificación permitirá a los docentes y directivos detectar a tiempo a los estudiantes que podrían requerir apoyo adicional, así como diseñar estrategias personalizadas para mejorar su desempeño.

Marco Teórico

Vectores y Matrices

“Los vectores y las matrices son elementos fundamentales en el estudio del álgebra lineal. Un vector puede entenderse como una lista ordenada de números que representa una magnitud con dirección y sentido en un espacio n -dimensional. Por su parte, una matriz es una estructura rectangular de números dispuestos en

filas y columnas, que puede representar sistemas de ecuaciones, transformaciones lineales o conjuntos de datos multivariados.

En el contexto del análisis de datos, cada fila de una matriz puede representar una observación (por ejemplo, un estudiante), y cada columna una característica o variable (como notas, asistencia o hábitos de estudio). Las operaciones matriciales, como la multiplicación, la transposición o la inversión, permiten manipular y transformar estos datos de manera eficiente". (Strang, 2016; Shlens, 2014).

Transformaciones Lineales

“Una transformación lineal es una función que preserva las operaciones de suma vectorial y multiplicación por un escalar. Matemáticamente, si T es una transformación lineal, entonces para vectores u y v , y escalar c , se cumple que:

$$T(u + v) = T(u) + T(v), \quad T(c * u) = c * T(u)$$

En la práctica, las transformaciones lineales permiten cambiar la base del espacio vectorial en el que se representan los datos, facilitando así su visualización y análisis. En PCA, por ejemplo, los datos originales se transforman a un nuevo sistema de coordenadas en el que las variables están desacopladas (no correlacionadas)". Strang, G. (2016). Introduction to Linear Algebra (5th ed.). Wellesley-Cambridge Pre

Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales es una técnica estadística utilizada para reducir la dimensionalidad de grandes conjuntos de datos, manteniendo al mismo tiempo la mayor cantidad posible de información. PCA transforma el conjunto original de variables correlacionadas en un nuevo conjunto de variables no correlacionadas llamadas **componentes principales**.

Este proceso implica:

1. Centralizar los datos (restar la media).
2. Calcular la matriz de covarianza.
3. Obtener los autovalores y autovectores de dicha matriz.
4. Proyectar los datos originales en las direcciones de los autovectores asociados a los mayores autovalores.

Relación con Machine Learning

“La reducción de dimensionalidad mediante PCA es especialmente útil como paso previo en algoritmos de Machine Learning. Al disminuir la cantidad de variables, se

mejora la eficiencia computacional, se reduce el riesgo de sobreajuste y se facilita la visualización de los datos en problemas complejos.

Una vez transformados, los datos pueden ser utilizados en algoritmos de clasificación como:

- K-Nearest Neighbors (KNN): clasifica nuevos datos según la mayoría de sus vecinos más cercanos en el espacio reducido.
- Support Vector Machines (SVM): encuentra el hiperplano óptimo que separa las clases de forma lineal o no lineal.
- Árboles de Decisión: construyen un modelo en forma de árbol basado en condiciones lógicas derivadas de los datos reducidos.

En conjunto, el uso de PCA en combinación con técnicas de Machine Learning permite desarrollar sistemas de análisis académico más precisos y personalizados". (Geron, 2019; Shlens, 2014).

Desarrollo del Trabajo

Descripción detallada de las actividades y procesos realizados:

El trabajo se desarrolló con el objetivo de analizar el rendimiento académico de un grupo de estudiantes utilizando técnicas de análisis de datos y aprendizaje automático. A continuación, se describen las etapas realizadas:

Recolección y preparación de datos:

Se creó un conjunto de datos simulados que incluye información académica y de comportamiento de siete estudiantes. Las variables incluidas fueron: nombre, nota en Matemáticas, nota en Lengua, porcentaje de asistencia, horas de estudio por día y el nivel de rendimiento categorizado como Bajo, Medio o Alto.

Exploración inicial:

Se realizó una vista preliminar del conjunto de datos para verificar su integridad y consistencia. Se identificó que todas las variables eran numéricas excepto la clase objetivo ('Rendimiento') y los nombres de los estudiantes.

Reducción de dimensionalidad con PCA:

Se aplicó Análisis de Componentes Principales (PCA) para reducir las variables a dos componentes principales. Esto permitió visualizar mejor la distribución de los datos en un plano bidimensional y facilitó la interpretación de los resultados. Además, se examinó la varianza explicada por cada componente.

Clasificación con KNN:

Se utilizó el algoritmo K-Nearest Neighbors con $k=3$ para clasificar el nivel de rendimiento de los estudiantes. Se dividieron los datos en conjuntos de entrenamiento y prueba (70%-30%). Se entrenó el modelo con los datos de entrenamiento y se evaluó el desempeño en los datos de prueba usando una matriz de confusión y un reporte de clasificación.

Visualización de resultados:

Se generó un gráfico de dispersión con los dos componentes principales (PC1 y PC2), donde se identificaron los estudiantes por nombre y se colorearon los puntos según el rendimiento. Esta visualización facilitó el análisis del agrupamiento de los estudiantes según sus características académicas.

Interpretación final:

Se compararon los valores reales y predichos de rendimiento por cada estudiante, lo cual permitió observar el desempeño del modelo y detectar posibles errores de clasificación. Este análisis fue útil para evaluar la efectividad del enfoque y las posibles mejoras futuras.